AI스킬노트 · 무료 자료 · 2026년 10월 공식 문서 확인

Claude Code
토큰 아끼는 법
한 장에

140k 스마트 존, Opus 5.5에서 지키는 공식 방법 5가지 + 덤 3가지

/clear **/compact** **Haiku 서브에이전트** **/context** **/effort**

복사해 쓰는 설정 파일

AI스킬노트 · 영상 「Claude Code 스마트 존, Opus 5.5에서 다시 보기」의 정리 자료예요

PART 1

왜 아껴야 하나요

Claude Code는 요청할 때마다 대화 전체를 함께 보내요.

> **공식 비용 문서 (code.claude.com/docs/en/costs)**
> "Claude Code sends your full conversation with every request"
> "Stale context wastes tokens on every subsequent message."

140k는 누구의 기준인가요

유명 개발자 Matt Pocock이 강연에서 말한 '스마트 존' 선이에요. 그때 Matt는 Opus 4.8을 medium effort로 쓰고 있었어요. 공식 문서의 규칙은 아니지만, Opus 5.5에서도 지키면 토큰과 시간을 아낄 수 있는 좋은 습관이에요.

우리가 재 본 숫자 (2026-10-11, 공개 저장소 하나, 한 번)

때	/context 값
새 대화, 아무것도 묻기 전	**19.6k** 토큰 (시스템 프롬프트·도구·스킬 목록·CLAUDE.md)
파일 31개를 읽은 뒤	**116.8k** 토큰
요청 하나를 더 한 뒤	**140.3k** 토큰

저장소와 작업에 따라 숫자는 달라져요.

다시 읽는 것도 공짜는 아니에요

Opus 5.5 입력은 백만 토큰당 **$4**, 캐시에서 다시 읽으면 **$0.20**이에요(Opus 5.5 모델 페이지). 싸지만, 대화가 길수록 요청마다 쌓여요. 구독 요금제에서도 같은 원리로 사용량이 줄어요.

PART 2

공식 문서의 방법 5가지

영상에 나온 순서 그대로예요.

1 다른 일로 넘어갈 땐 `/clear`

"/clear costs nothing" · 나중에 다시 볼 대화는 `/clear` 전에 `/rename`, 돌아올 땐 `/resume`

2 같은 일을 이어 가면 `/compact` 뒤에 남길 내용을 적기

예: `/compact 테스트 결과와 바뀐 코드 위주로 남겨 줘` · /compact는 대화 전체를 읽는 큰 요청이라, 일이 바뀌었으면 /clear가 먼저

3 읽기·검색만 하는 일은 Haiku 서브에이전트에게

"For simple subagent tasks, specify model: haiku in your subagent configuration" · 설정 파일은 PART 5. 우리 측정에서 모델을 정하지 않은 서브에이전트는 메인과 같은 Opus 5.5로 돌았고, 그 단계 비용은 바로 앞 단계의 4.8배였어요.

4 `/context` 로 무엇이 자리를 차지하는지 보기

"Run /context to see what's consuming space."

5 effort는 새 대화를 시작할 때 `/effort` 로 정하기

Opus 5.5 기본값은 medium. 대화 중간에 바꾸면 캐시가 깨져서 쌓인 대화를 할인 없이 다시 읽어요.

> **덤**
> 지금까지 쓴 양은 `/usage`. 부탁은 구체적으로: '이 코드 좋게 해 줘' 대신 '로그인 함수에 입력 검사 추가'.

참고: Claude Code는 1M 창 모델에서 기본으로 약 967K 토큰에 자동 정리해요(모델 설정 문서). 그 전까지는 계속 쌓여요.

PART 3

Anthropic 글의 덤 3가지

「Maximizing the value of your Claude Code sessions」(Lydia Hallie, Anthropic, 2026-08-14)

Q. 파일은 이름 앞에 @를 붙여 지정하기

원문: "@-mention files instead of naming them." Claude가 파일을 찾아 여는 단계를 건너뛰어요.

Q. 자리를 비우기 전에 /compact

원문: "/compact before you take a break from your keyboard. The prompt cache expires after an hour" (구독 기준 한 시간, API 키는 5분)

Q. 대화가 엉뚱한 방향으로 갔으면 /compact 대신 /rewind

원문 요지: 되감기는 비용이 들지 않아요("costs nothing"). 뒤쪽만 잘라 내서 앞부분 캐시는 그대로예요.

> **같은 글의 한 줄**
>
> "turn 40 is also re-reading the 39 turns before it" · 40번째 요청은 앞의 39번을 다시 읽어요.

원문: https://claude.com/resources/articles/maximizing-the-value-of-your-claude-code-sessions

PART 4

토큰 점검표

대화를 시작할 때 · 일하는 중 · 마무리할 때

시작할 때

☐ `/context` 로 무엇이 자리를 차지하는지 본다
☐ 이전 대화와 상관없는 일이면 새 대화로
☐ 모델과 `/effort` 는 지금 정한다(중간에 바꾸면 캐시가 깨짐)

일하는 중

☐ 다른 일로 넘어가면 `/clear` (다시 볼 대화는 먼저 `/rename`)
☐ 같은 일은 `/compact 남길 내용`
☐ 파일을 많이 읽거나 검색만 하는 일은 Haiku 서브에이전트에게
☐ 파일은 `@파일이름` 으로 지정
☐ 엉뚱한 방향이면 `/rewind`
☐ 부탁은 범위를 좁혀 구체적으로

마무리할 때

☐ `/usage` 로 쓴 양 확인
☐ 자리를 비우기 전 `/compact` (캐시는 한 시간 뒤 사라짐)
☐ 몇 시간째 열린 세션은 정리할 때인지 본다

"A session that has been open for hours can use far more of your plan limits than your activity suggests"

PART 5

Haiku 서브에이전트 설정 (복사용)

이 프로젝트만: `.claude/agents/` · 모든 프로젝트: `~/.claude/agents/`

1. 읽기 전용 조수 · `.claude/agents/reader.md`

```
---
name: reader
description: Reads and searches files without editing them, then returns a short summary. Us
e for broad file reading, log reading and code search.
tools: Read, Grep, Glob
model: haiku
---
You read and search files only. Never edit files.
Return a short summary: what you found, file paths with line numbers, and anything that look
ed wrong.
Keep the summary under 30 lines.
```

`model: haiku` 한 줄이 핵심이에요. 쓰는 법: "reader 서브에이전트로 src 폴더를 훑어보고 요약해 줘"

2. 기본 Explore를 Haiku로 · `.claude/agents/explore.md`

```
---
name: Explore
description: Fast read-only agent for searching and analyzing codebases. Use when you need t
o find files, search code or understand a codebase without making changes.
tools: Read, Grep, Glob
model: haiku
---
Search and read the codebase to answer the question. Do not edit files.
Report file paths with line numbers and a short explanation.
```

공식 문서: "A user or project subagent named Explore overrides the built-in and keeps its own model field, so define one with model: haiku" · Haiku 5.5 입력은 백만 토큰당 $0.10부터예요.

> **주의**
> 복잡한 설계나 어려운 버그는 메인 모델이 더 나아요. 비유하면 Opus는 꼼꼼한 선배, Haiku는 빠르고 저렴한 조수예요.

공식 문서 링크

Claude Code 비용	code.claude.com/docs/en/costs
서브에이전트	code.claude.com/docs/en/sub-agents
모델 설정 (자동 정리 시점)	code.claude.com/docs/en/model-config
Opus 5.5 새로 바뀐 점	platform.claude.com/docs/en/models/opus-5-5/whats-new-opus-5-5
Opus 5.5 모델 페이지 (가격)	platform.claude.com/docs/en/models/opus-5-5/overview
Anthropic 글 (덤 3가지)	claude.com/resources/articles/maximizing-the-value-of-your-claude-code-sessions

> **AI스킬노트**
> 공식 문서로 확인한 Claude 사용법을 정리해요. 구독하시면 이런 무료 자료를 꾸준히 받으실 수 있어요.

공식 문장은 2026-10-11~14에 확인했어요. 문서는 바뀔 수 있으니 쓰기 전에 링크를 한 번 열어 보세요. 측정 숫자는 공개 저장소 하나에서 한 번 잰 값이에요. AI스킬노트는 Anthropic과 관계가 없어요.