AI스킬노트 · 무료 자료 · A편 아키텍처 지도

ChatGPT는 어떻게 빨리 답할까
AI 챗봇 아키텍처 지도

서버 한 대에서 사용자 100만 명 규모까지, 막힐 때마다 더하는 상자 여덟 개



AI스킬노트 · ChatGPT는 한 주에 12억 명 넘게 씁니다(OpenAI, 2026-10-07). 지도는 공식 문서와 기업 기술 블로그를 바탕으로 한 우리 정리예요.

PART 1

정거장 여덟 개 한눈에

막힌 곳 → 더한 상자 → 예시 도구 → 공식 문서 근거

정거장	막힌 곳	더한 상자	예시 도구	공식 근거
1. 서버 한 대	AI 답을 기다리는 동안 다음 요청이 줄을 섬	비동기 서버	asyncio · Node.js	OpenAI 지연 시간 안내서: 스트리밍으로 기다림 줄이기
2. DB 분리	연결마다 프로세스, 연결 한도	커넥션 풀	PgBouncer	PostgreSQL 문서: 기본 연결 한도 보통 100개
3. 서버 여러 대	한 대가 멈추면 전체가 멈춤, 서버 메모리에 남은 대화	로드 밸런서 + 상태 없는 서버	Nginx · ALB · Redis(세션)	AWS 문서: 헬스 체크 기본 30초 · 트웰브 팩터: 스티키 세션 쓰지 않기
4. 캐시	같은 데이터를 반복해서 읽음	캐시 어사이드 + 프롬프트 캐싱	Redis · Claude 프롬프트 캐싱	Claude 가격표: 캐시 읽기는 기본 입력 가격의 10%
5. 대기열과 한도 ★	AI API 속도 제한(429), 재시도 악순환, 몰아 보내기	대기열 + 워커 + 재시도 규칙	Kafka · RabbitMQ · SQS	Claude 문서: 분당 한도도 초 단위로 적용될 수 있음 · 배치는 정가의 50%
6. DB 복제와 샤딩	데이터베이스 한 대가 읽기·쓰기를 다 받음	읽기 복제본(샤딩은 마지막)	PostgreSQL 복제	OpenAI: 쓰기 주 서버 한 대 + 읽기 복제본 50대 가까이
7. CDN	멀리서 접속하면 오가는 시간	CDN(화면 파일만)	Cloudflare · CloudFront	Cloudflare 문서: HTML·JSON은 기본으로 캐시하지 않음
8. 모니터링	어디가 느린지 안 보임	신호 넷 + 토큰 기록	Grafana · 사용량 API	구글 SRE 책: 꼭 볼 신호 4가지

★ 다섯 번째 정거장은 일반 웹 앱에는 없는 AI 앱만의 벽이에요. 서버와 데이터베이스는 직접 늘릴 수 있지만, AI API 속도 제한은 마음대로 늘릴 수 없어요.

PART 2

첫 번째 벽은 기다림 (우리 실험)

같은 컴퓨터에서 서버 코드 구조만 바꿨어요

실제 AI 대신 **2초 뒤에 답하는 시험용 서버**를 두고, 요청 40개를 한꺼번에 보냈어요. 서버마다 다섯 번씩 재서 가운데 값을 적었어요.

서버 구조	마지막 요청이 답을 받기까지
한 번에 하나씩 처리	80.4초
스레드 여덟 개	10.1초
비동기(기다리는 동안 다음 요청)	**2.1초**

이 실험에서 서버는 계산을 거의 하지 않고 답을 기다리기만 했어요. 그래서 상자를 더하기 전에, 기다리는 동안 다른 요청을 받게 만드는 게 먼저예요.

직접 돌려 보기

```
python wait_bench.py
```

파이썬 표준 라이브러리만 써요(설치할 것 없음). 내 컴퓨터 안에서만 요청을 주고받고, 결과는 results 폴더에 저장돼요. 숫자는 컴퓨터마다 다르지만 차이가 생기는 원리는 같아요.

PART 3

정거장별 AI에게 물어볼 문장 (복사용)

Claude Code든 다른 AI 코딩 도구든 그대로 붙여 넣어요

1. 서버 한 대

이 앱이 AI API의 답을 기다리는 동안 다른 요청을 받을 수 있는 구조(비동기)인지 확인해 줘. 아니라면 어느 파일의 어떤 부분을 바꿔야 하는지 알려 줘.

2. DB 분리

앱과 데이터베이스가 같은 서버에서 도는지, 데이터베이스 연결을 요청마다 새로 여는지 확인해 줘. 커넥션 풀을 쓰도록 바꾸는 계획도 세워 줘.

3. 서버 여러 대

이 서버를 여러 대로 늘려도 문제가 없는지 봐 줘. 서버 메모리에만 저장하는 세션이나 대화 상태가 있으면 전부 찾아 줘.

4. 캐시

자주 읽고 잘 바뀌지 않는 데이터를 찾아 캐시할 후보를 표로 정리해 줘. AI에 보내는 프롬프트 앞부분이 매번 똑같은지도 확인해 줘.

5. 대기열과 한도

AI API 호출 코드에 429 처리, retry-after만큼 기다리기, 간격을 늘려 가며 다시 보내기, 요청 속도 고르게 맞추기가 있는지 확인하고 없는 것을 추가하는 계획을 세워 줘.

6. DB 복제와 샤딩

읽기와 쓰기 중 어느 쪽이 많은지 코드에서 추정하고, 읽기 복제본으로 옮길 수 있는 조회를 찾아 줘.

7. CDN

CDN으로 보내도 되는 정적 파일과, 사람마다 달라서 CDN에 두면 안 되는 응답을 나눠 줘.

8. 모니터링

응답 시간·요청량·오류·자원 사용량, 그리고 토큰(캐시 안 된 입력·캐시 읽기·캐시 저장·출력)을 기록하는 곳이 있는지 확인해 줘.

PART 4

체크리스트 · ChatGPT의 실제 답 · 한계

오늘 가져갈 것

☐ 막히면 먼저 무엇이 기다리는지 본다
☐ 상자는 막힌 문제가 생길 때 하나씩 더한다
☐ AI 한도 앞에는 대기열과 재시도 규칙을 둔다
☐ 서버 메모리에 대화를 남기지 않는다
☐ 샤딩은 복제본과 캐시로 버틸 수 없을 때

OpenAI가 공개한 구조 (사용자 8억 명 당시)

데이터베이스 앞에 PgBouncer를 두고 평균 연결 시간을 50밀리초에서 5밀리초로 줄였고, 읽기 대부분은 캐시 층이 먼저 받아요. 나머지 읽기는 복제본 50대 가까이가 나누고, 쓰기는 주 서버 한 대가 맡아요. 재시도가 한꺼번에 몰리지 않게 다시 보내는 간격도 조심했다고 밝혔어요.

한계

100만 명은 이야기 장치예요. 100만 명일 때 서버가 몇 대라는 숫자는 쓰지 않았어요. 실험은 컴퓨터 한 대와 시험용 서버의 결과라 실제 AI API·서버에서는 숫자가 달라요. 정거장 순서는 공식 문서를 바탕으로 한 우리 정리예요.

출처: OpenAI 'Scaling PostgreSQL to power 800 million ChatGPT users'(2026-01-22) · OpenAI 'GPT-6 for everyone'(2026-10-07) · PostgreSQL·AWS·Redis·Cloudflare·Claude 공식 문서 · 12factor.net · Google SRE book · Notion·Figma 기술 블로그 · 광고·협찬 아님