AI스킬노트 · 무료 자료 · A편 아키텍처 지도

ChatGPT 답은 왜 한 글자씩 올까
AI 챗봇 스트리밍 지도

사용자와 서버 사이의 선 하나, 정거장 여덟 개



AI스킬노트 · ChatGPT는 한 주에 12억 명 넘게 씁니다(OpenAI, 2026-10-07). 지도는 공식 문서·표준·기업 기술 블로그를 바탕으로 한 우리 정리예요.

PART 1

정거장 여덟 개 한눈에

질문 → 찾은 답 → 공식 근거

정거장	질문	찾은 답	공식 근거
1. 요구 사항	왜 한 번에 보내면 안 되나	첫 글자는 빨리 · 긴 답도 안 끊기게 · 끊겨도 이어서	OpenAI 지연 시간 안내서: 스트리밍이 가장 효과적
2. 냅킨 계산	무엇을 세나	초당 요청 수보다 동시에 열린 연결 수	MDN: HTTP/2가 아니면 같은 사이트 SSE 연결 6개, HTTP/2 기본 100개
3. 네 가지 방식	폴링 · 롱폴링 · SSE · 웹소켓	AI 채팅은 질문 한 번 + SSE로 길게 받기	OpenAI 웹소켓 모드: 도구 호출 20번+ 작업에서 최대 40% 단축
4. 조각의 모양	한 글자씩 오는 데이터	빈 메시지 틀 → 글자 조각 이벤트 여러 번 → 끝 이벤트, 사이사이 핑	Claude 스트리밍 문서
5. 중간 상자 ★	코드는 맞는데 한꺼번에 뜬다면	프록시 버퍼링 끄기 · 오래 생각할 때 핑/빈 줄	nginx 버퍼링 기본 켜짐 · ALB 유휴 60초 · nginx 읽기 사이 60초 · Cloudflare 125초 · SSE 표준 15초쯤마다 주석 줄
6. 저장	대화는 누가 기억하나	앱이 저장 · 끝 이벤트 뒤 한 줄 · 시간순 메시지 번호	OpenAI: 요청은 독립, 이어 붙인 이전 입력도 매번 과금
7. 열 배	무엇이 먼저 막히나	열린 연결 수 · 연결 쥔 앞층만 상태, 뒤층은 무상태	Slack 게이트웨이 · Cloudflare 세션 고정 vs 12팩터
8. 장애	답이 끊기면	생성과 연결 분리 · 이어 받기 · 재연결은 사람마다 다른 간격	OpenAI 백그라운드 · SSE Last-Event-ID · Claude · AI SDK

PART 2

선 하나 위의 네 가지 방식

배달 앱으로 보면: 새로 고침 · 나오면 연락 · 실시간 위치 · 라이더와 채팅

방식	어떻게	주의할 점	잘 맞는 곳
폴링	브라우저 → 서버를 계속 물음	대부분 빈 응답	변화가 드문 상태 확인
롱폴링	새 소식이 생길 때까지 요청을 붙잡음	오래 붙잡으면 시간 초과	SSE·웹소켓을 못 쓸 때의 대안
SSE	한 번 열면 서버 → 브라우저로 계속	한 방향, 중간 장비 버퍼링 주의	AI 채팅 답 받기, 진행 상황 알림
웹소켓	연결 전환 뒤 양쪽이 아무 때나	연결마다 상태를 쥔 서버가 필요	사람끼리 채팅, 도구 호출이 많은 긴 작업

고르는 법

질문은 한 번, 답은 길게 받는 AI 채팅이면 SSE. 사람끼리 주고받는 서비스면 웹소켓. 도구를 여러 번 주고받는 긴 에이전트 작업이면 웹소켓 모드도 검토.

PART 3

AI에게 물어볼 점검 문장 (복사용)

Claude Code든 다른 AI 코딩 도구든 그대로 붙여 넣어요

스트리밍 점검

이 챗봇이 AI 답을 스트리밍으로 받아서 받는 즉시 브라우저로 넘기는지 확인해 줘. 중간에 모아서 보내는 코드가 있으면 찾아 줘.

중간 상자

nginx나 로드 밸런서 같은 중간 장비 설정에서 응답 버퍼링이 켜져 있는지, 유휴 시간 초과가 몇 초인지 찾아서 표로 정리해 줘.

핑

AI가 오래 생각하는 동안에도 연결이 끊기지 않게, 일정 간격으로 핑이나 빈 주석 줄을 보내는지 확인하고 없으면 추가 계획을 세워 줘.

이어 받기

답을 받다가 연결이 끊기면 어떻게 되는지 설명해 줘. 생성과 연결을 떼어 놓고 마지막으로 받은 지점부터 이어 받게 바꾸는 방법을 제안해 줘.

저장

완성된 답을 언제 데이터베이스에 저장하는지, 메시지 번호가 시간순으로 정렬되는지 확인해 줘.

PART 4

면접 꼬리 질문 · 체크리스트 · 한계

Q. AI 채팅에 웹소켓 대신 SSE를 많이 쓰는 이유는?

질문은 한 번 보내고, 답은 서버에서 브라우저로 한 방향으로 길게 흐르기 때문이에요. 일반 HTTP 요청 위에서 받을 수 있어 단순하고, OpenAI·Claude API도 SSE로 답을 보내요. 웹소켓은 양쪽이 아무 때나 주고받아야 하거나, 도구 호출이 아주 많은 긴 작업일 때 고려해요.

Q. 스트리밍 코드가 맞는데 화면에는 답이 한꺼번에 뜬다면 어디를 보나요?

중간 장비의 버퍼링을 먼저 봐요. nginx는 프록시 버퍼링이 기본으로 켜져 있어서 작은 조각을 모았다가 보내요. 설정에서 끄거나, 응답 헤더 X-Accel-Buffering: no로 응답마다 끌 수 있어요.

Q. 답을 생성하는 도중에 연결이 끊기면 어떻게 설계하나요?

연결 하나에 생성을 묶어 두면 연결이 끊길 때 생성도 취소돼요. 생성은 뒤에서 계속 돌리고, 클라이언트는 마지막으로 받은 이벤트 번호를 알려 그다음부터 이어 받게 해요. 많은 사용자가 한꺼번에 다시 붙지 않도록 재연결 간격은 사람마다 다르게 둬요.

오늘 가져갈 것

☐ AI 채팅은 질문 한 번 + SSE로 길게 받는다
☐ 답이 한꺼번에 뜨면 중간 상자의 버퍼링부터 본다
☐ 오래 생각할 때 핑이나 빈 줄로 연결을 살려 둔다
☐ 끊긴 답은 생성과 연결을 떼어야 이어 받는다
☐ 열 배가 되면 요청 수보다 열린 연결 수를 센다

한계: ChatGPT·claude.ai 앱 자체가 어떤 전송 방식을 쓰는지는 공식 문서가 없어 다루지 않았어요. 고르는 법과 층 나누기는 우리 정리예요. 연결 수 사례는 글이 나온 해(Slack 2023, Discord 2017, Gitter 2015)의 값이에요.

출처: OpenAI·Claude·MDN·nginx·AWS·Cloudflare 공식 문서 · RFC 6202·6455 · WHATWG HTML 표준 · Slack·Discord·우아한형제들·Gitter 기술 블로그 · Vercel AI SDK 문서 · 광고·협찬 아님